华中科技大学

课程设计报告

强化学习（研）

学　　院	计算机科学与技术学院
班　　级	计科 2104 班
姓　　名	张三
学　　号	U202112345

2026 年 10 月

目 录

1 小组工作介绍 1
1.1 项目背景与任务 1
1.2 总体方案与小组分工 1
2 本人工作 2
2.1 负责内容 3
2.2 实现过程 3
2.3 结果与分析 4
3 效果展示 5
3.1 运行效果截图 5
3.2 演示视频 7
3.3 定量结果 8
4 个人感想与思考 10
4.1 主要收获 10
4.2 不足与改进思路 10
5 其他小组展示的启示 11
5.1 印象较深的工作 11
5.2 对本组工作的启发 11
参考文献 12

1 小组工作介绍

1.1 项目背景与任务

赛车驾驶是一个连续决策问题。车辆进入弯道时，驾驶策略需要根据道路方向、车身姿态和速度及时调整转向与制动。过早减速会增加用时，减速不足则可能使车辆偏离道路。随机生成的赛道进一步要求策略能够应对不同曲率、弯道组合和道路布局。

本项目以 Gymnasium 的 CarRacing-v3 为仿真环境，使用 Box2D 模拟车辆和道路交互 [1]。任务是在规定时间内完成随机赛道，并兼顾驾驶速度与完赛可靠性。我们实现 PPO、SAC 和带终点控制的 Recurrent PPO（以下简称 RPPO）三种驾驶方案，通过独立赛道测试评估完赛率、驾驶用时与道路覆盖率，并用完整回合的视频展示典型驾驶行为。

项目交付包括可运行的环境与策略代码、训练配置、模型检查点、评测数据和驾驶演示。实验需要统一测试条件，并保留足够的回合信息，以便解释失败发生在何处以及它如何影响整体表现。

1.2 总体方案与小组分工

系统由环境封装、策略学习、独立评测和效果展示四部分组成。每次交互由策略读取当前车辆与道路状态，输出二维动作。控制接口将动作转换为转向、油门和刹车，环境推进车辆并返回下一状态、奖励及回合结束信息。训练阶段利用交互记录更新模型，评测阶段冻结权重，以确定性动作完成指定赛道。

三套方案均采用 34 维状态，包含纵横向速度、车身角速度、相对道路中心的偏移、方向关系、前方道路预瞄点、车轮接触、覆盖率、已用时间和近期控制等信息。几何特征由仿真环境提供。物理动作分为转向、油门和刹车，其中油门取有符号纵向控制的正部，刹车取负部的绝对值，避免同时给出油门和刹车。

表 1-1 三种方案

方案	策略结构与训练方式	策略结构与训练方式
PPO	前馈策略根据当前状态计算动作分布。使用广义优势估计和裁剪目标，按当前采样批次进行多轮更新。	第一维对预瞄控制器的转向作有限修正，第二维调节目标速度。由控制器计算纵向控制。
SAC	前馈策略结合经验回放、双 Q 网络、目标网络和自动熵温度更新，可多次使用已存储的交互经验。	与 PPO 共享转向修正、目标速度调节及车辆控制映射。
RPPO	前馈策略结合经验回放、双 Q 网络、目标网络和自动熵温度更新，可多次使用已存储的交互经验。	常规驾驶由策略直接输出转向与有符号纵向控制。覆盖率超过 90% 且车辆进入起终点附近区域时，启用终点预瞄控制，持续至本回合结束。

PPO 和 SAC 各使用种子 0、1、2 训练，每个种子预算为 196,608 个策略决策。两种方案各使用 4 个并行环境，每隔 32,768 个决策在固定 100 条赛道上验证。PPO 每个环境采样 256 步后组织批次更新，裁剪参数为 0.2。SAC 使用容量为 50,000 的回放缓冲区、256 的批量大小，前 5,000 个决策用于初始采样，目标熵为 −2。

RPPO 使用一个训练种子、8 个并行环境、128 维 LSTM 和长度为 32 的训练序列。训练预算为 393,216 个决策，评估使用 327,680 步检查点，并在部署时启用终点控制。最终选定的三套方案均在种子 1200000 至 1200299 的同一批 300 条独立赛道上测试。

表 1-2 小组分工

成员	负责内容	主要交付
范俊杰	环境与控制接口、完赛规则、统一评测、实验数据及展示流程	评测协议、模型索引、统计图表、成功和失败案例及演示材料
江鹤鸣	PPO 策略与价值网络、优势估计、裁剪更新及训练诊断	PPO 训练配置、各种子的检查点和训练分析
付晓如	SAC 策略、经验回放、双 Q 网络和自动熵温度	SAC 训练配置、各种子的检查点和评测分析
张朝阳	RPPO 时序策略、直接控制和终点控制	RPPO 检查点、记忆管理和终点控制说明、驾驶案例分析

2 本人工作

2.1 负责内容

我负责将三个算法的输出接入同一仿真环境，并建立可从模型检查点追溯到每条赛道结果的评测流程。具体工作包括明确状态和动作的接口，区分真实完赛、超时和其他终止情况，统一测试赛道和评价指标，核对训练与评测记录，以及整理图表、截图和完整驾驶视频。

在小组协作中，我与三位算法负责人确认模型配置、动作语义和最终使用的检查点。评测时，每份检查点都关联训练种子、所处训练步数和控制配置。这样可以从一条失败记录追溯到具体模型、赛道和回合，进一步核对当时的车速、车轮接触和道路覆盖变化。

2.2 实现过程

环境封装与回合边界。我将交互流程整理为环境重置、动作转换、仿真步进和回合统计。重置时传入赛道种子，并清空回合计数和控制状态。每次策略决策最多重复 4 个物理帧，若中途结束则记录实际执行帧数。环境按 50 帧/秒运行，回合上限为 1,000 帧，对应 20 秒。RPPO 的 LSTM 记忆只在当前回合内延续，进入下一条赛道时重新初始化。

完赛判定。我将道路覆盖率、回合终止和完赛状态分别记录。按项目的 lap 95 规则，车辆访问全部路块时可完成回合。若有未访问路块，则需在离开起点后正向重新进入起点，且覆盖率超过 95%，才满足相应的完赛条件。PPO、SAC 和 RPPO 共用这套规则。RPPO 的终点控制通过改变实际转向和速度帮助车辆通过末段，回合仍由环境规则判定。

模型与赛道管理。我将训练、验证和测试赛道分开。训练时随机生成赛道，验证赛道固定，用于观察训练变化和选择检查点。独立测试统一使用 300 条赛道，并在测试前确定各算法使用的检查点。PPO 和 SAC 分别评测三个训练种子，RPPO 评测一份模型，共得到 2,100 条模型与赛道的组合记录。我按模型逐一检查记录数、赛道编号和重复行，确保每份模型都有完整且一致的 300 条测

试。

指标计算与日志整理。逐赛道记录包含原始回报、物理帧数、覆盖率、完赛状态、终止标记和截断标记。用时由实际物理帧数除以 50 得到。对 PPO、SAC，我先计算各训练种子的统计量，再计算种子间均值。由于同一个赛道在不同种子下会重复出现，报告同时保留赛道数量和训练种子数量。最佳检查点和最终检查点也单独记录，便于追溯验证选模与训练结束时的差异。

图表与驾驶演示。我将完赛率、完赛平均用时和含失败惩罚的平均用时并列展示，并用限时完赛曲线查看不同时间内完成的回合比例。驾驶演示覆盖完赛与未完赛案例，重点查看车辆在弯道、路缘和终点附近的表现。检查每段视频时，我将帧数与回合记录对应，并用车身角速度、接触车轮数和道路覆盖率补充对画面的解释。

2.3 结果与分析

统一评测流程能够在相同赛道上区分不同驾驶表现。SAC 在本组配置下获得最高完赛率，RPPO 在完赛回合中的平均用时最短。PPO 的训练曲线出现阶段性波动，其三个种子的最佳验证完赛率为 92%、94%、96%，训练结束时分别为 91%、88%、90%。这项对照说明，选择检查点时需要保留验证表现和训练进度，仅凭训练步数无法判断模型的实际驾驶效果。

我在评测中重点检查了三类失败。PPO 在赛道 1200289 上长时间处于草地旋转状态，回合推进很少。SAC 在赛道 1200212 上覆盖率达到 99.70%，仍在 20 秒时被截断，说明覆盖率和完赛需要分别统计。RPPO 在赛道 1200085 上较早停滞，末段车速接近零，覆盖率停留在 16.51%。由于该回合未达到终点控制的覆盖率条件，它反映的是常规驾驶阶段的局部停滞。三种现象都表现为未完赛，但对应的分析和改进方向不同。

3　效果展示

3.1　运行效果截图

训练完成后，智能体能够在 CartPole 环境中持续保持杆体平衡。图 3-1 为运行过程中的界面截图示例。

三种方案各展示两条完赛赛道和一条未完赛赛道。每组画面包含回合不同阶段的车辆位置、道路形状和接触状态。图中的“完赛”或“未完赛”对应完整回合的结果。

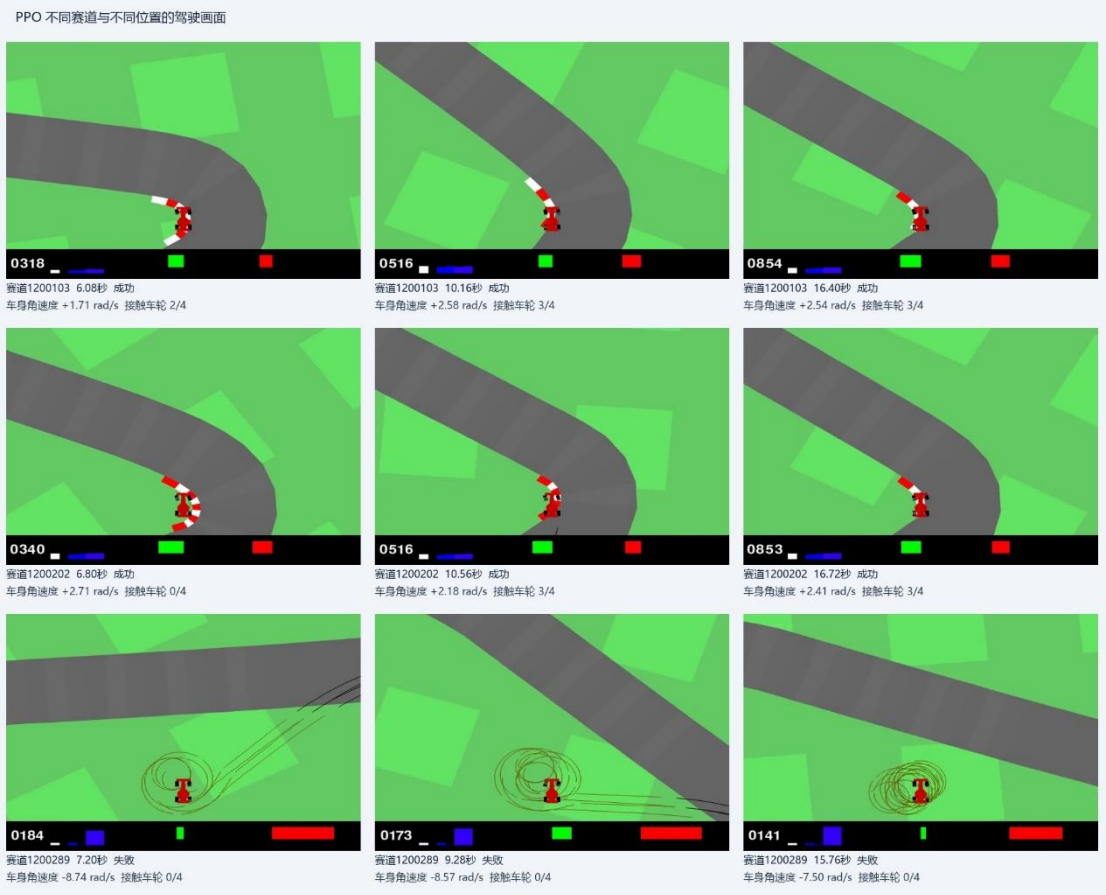


图 -　PPO 的弯道驾驶与未完赛表现

PPO 在赛道 1200103 和 1200202 上可以连续通过弯道并完成回合。部分弯道中车辆接近路缘，仍能回到道路内继续前进。赛道 1200289 上出现持续离路旋转，约 80.8% 的决策时刻四轮均未接触道路，最终覆盖率为 22.02%。

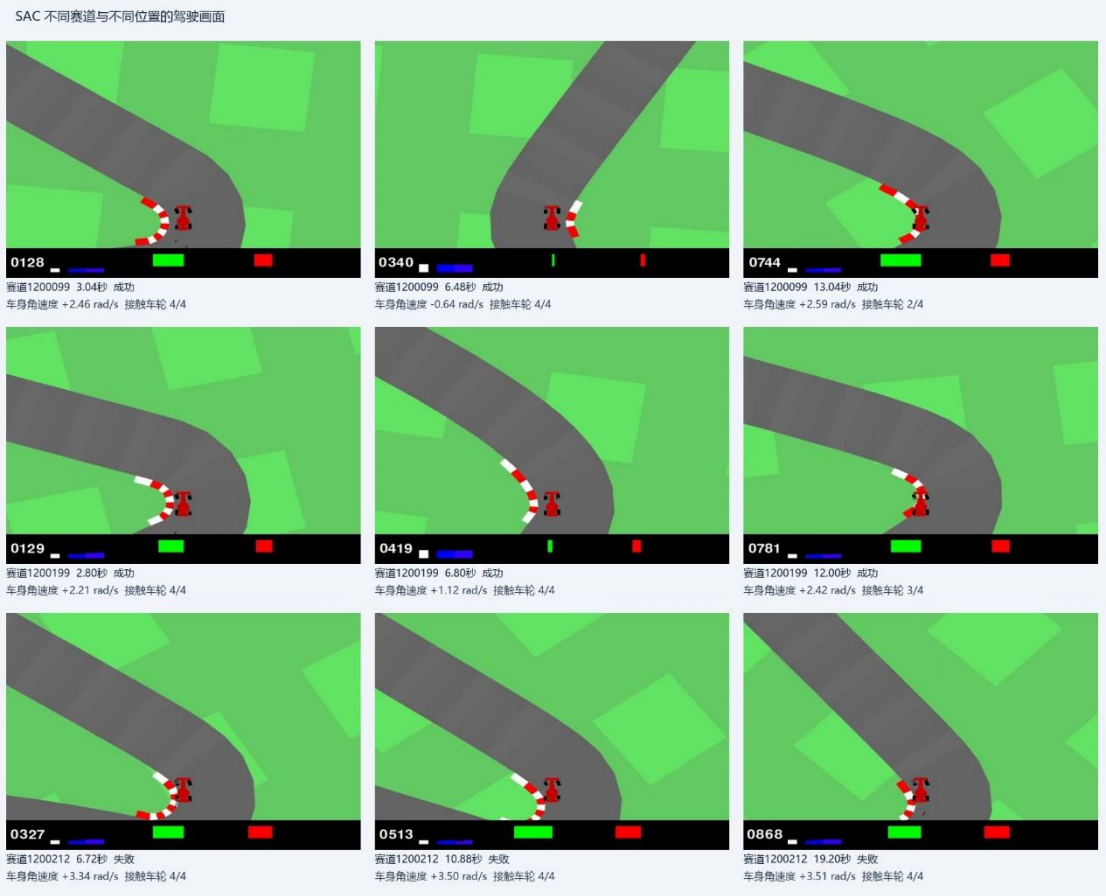


图 3-2　SAC 的弯道驾驶与未完赛表现

SAC 在赛道 1200099 和 1200199 上均访问全部路块，能够持续通过不同弯道。赛道 1200212 在超时前已覆盖 99.70% 的道路，逐决策记录中没有出现四轮同时失去道路接触。这一回合的主要特征是高覆盖率下未能在时限内满足完赛条件。

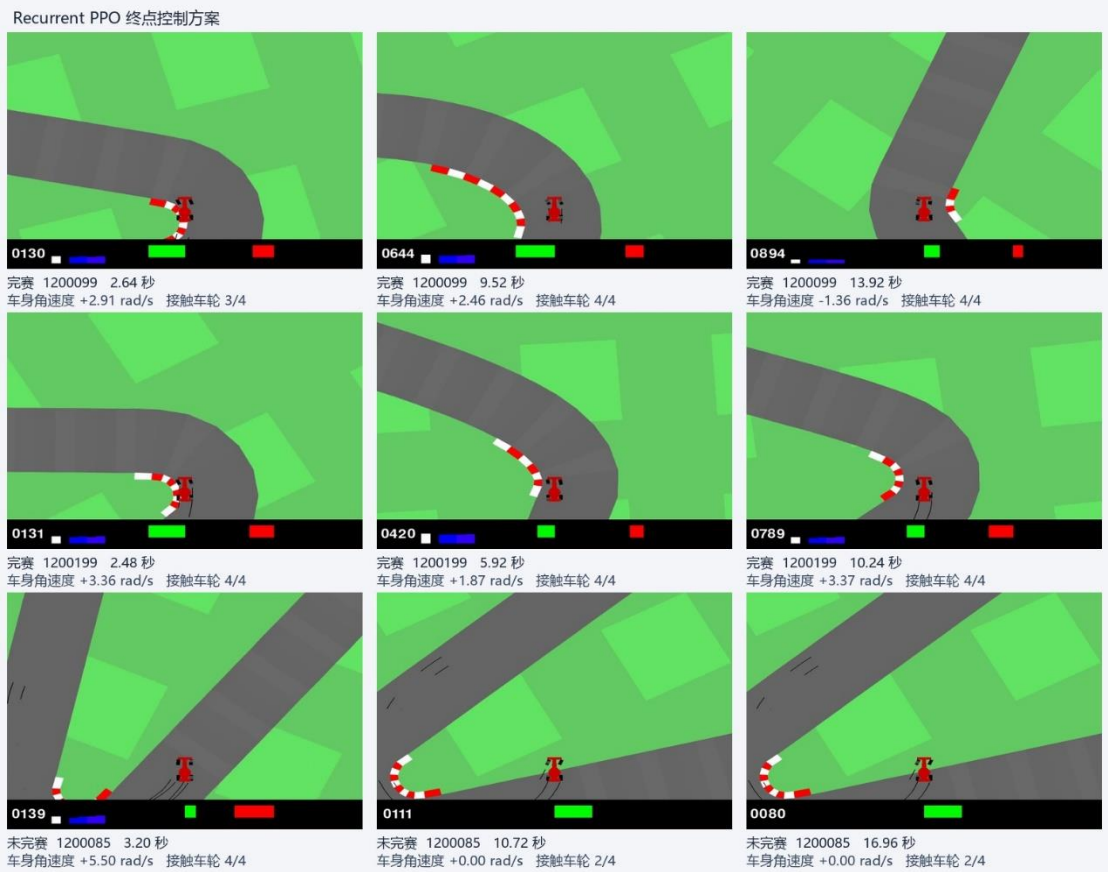


图 3-3 RPPO 的弯道驾驶与未完赛表现

RPPO 在赛道 1200099 和 1200199 上分别以 14.68 秒和 13.38 秒完成，均达到 100% 的覆盖率。在赛道 1200085 上，车辆于道路边缘附近停滞，后期仍有两个车轮接触道路。接触状态和覆盖率随时间的变化有助于区分局部停滞与整车驶离道路。

3.2 演示视频

表 3-3 演示视频地址

方案	完赛案例一	完赛案例二	未完赛案例
PPO	PPO/完赛_120103.mp4	PPO/完赛_120202.mp4	PPO/未完赛_1200289.mp4
SAC	SAC/完赛_1200099.mp4	SAC/完赛_1200199.mp4	未完赛_1200212.mp4
RPPO	未完赛_120021	RPPO_finish/完	RPPO_finish/未

2.mp4	赛_1200199.mp4	完赛_1200085.mp4

赛道 1200099 和 1200199 可用于并排观察 SAC 与 RPPO 在相同道路上的驾驶节奏。两条案例中 RPPO 的完赛用时都更短。三条未完赛视频可分别观察持续离路、高覆盖率超时与道路边缘停滞。

3.3 定量结果

表 3-1 给出了不同设置下的训练结果对比。其中“平均回报”为最后 100 个回合的平均值，“成功率”为达到目标回报的回合占比。

完赛率按符合完赛条件的回合比例计算。完赛平均用时只统计完赛回合。含失败惩罚的平均用时在统计中将未完赛记为 40 秒，完赛按实际用时计入，仿真时限为 20 秒。原始回报取环境原始累计值。PPO、SAC 的用时、回报和覆盖率按三份模型的指标取均值，RPPO 对应一份模型。

表 3-4 同一批 300 条独立赛道的测试结果

方案	训练种子数	完赛回合 / 评估回合	完赛率	完赛平均用时（秒）	含失败惩罚的平均用时（秒）	原始平均回报	平均覆盖率
PPO	3	779 / 900	86.56%	16.840	19.953	842.78	92.91%
SAC	3	885 / 900	98.33%	16.164	16.559	916.88	99.80%
RPPO	1	289 / 300	86.56%	14.660	15.589	903.30	97.76%

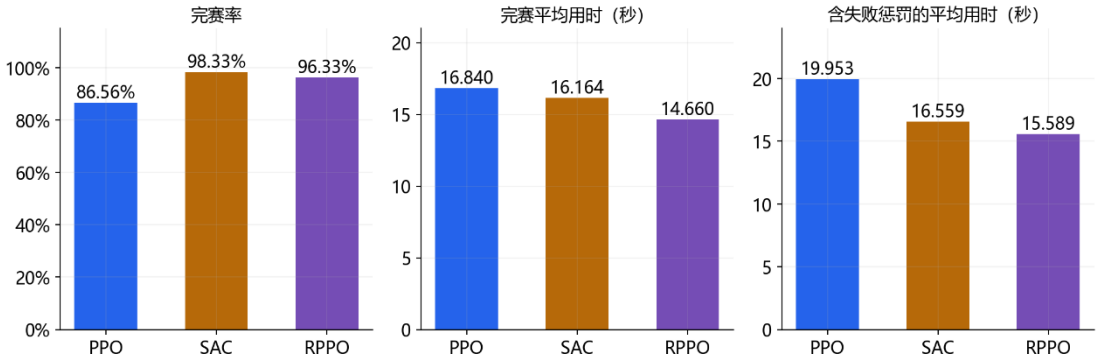


图 3-4　三种方案统一测试结果

SAC 的完赛率比 PPO 高约 11.78 个百分点，在这批赛道中完成可靠性最高。RPPO 的完赛平均用时比 SAC 短约 1.50 秒，其含失败惩罚的平均用时也最低。两项结果一起说明，SAC 更经常完成赛道，RPPO 的速度优势则在计入失败后仍然存在。

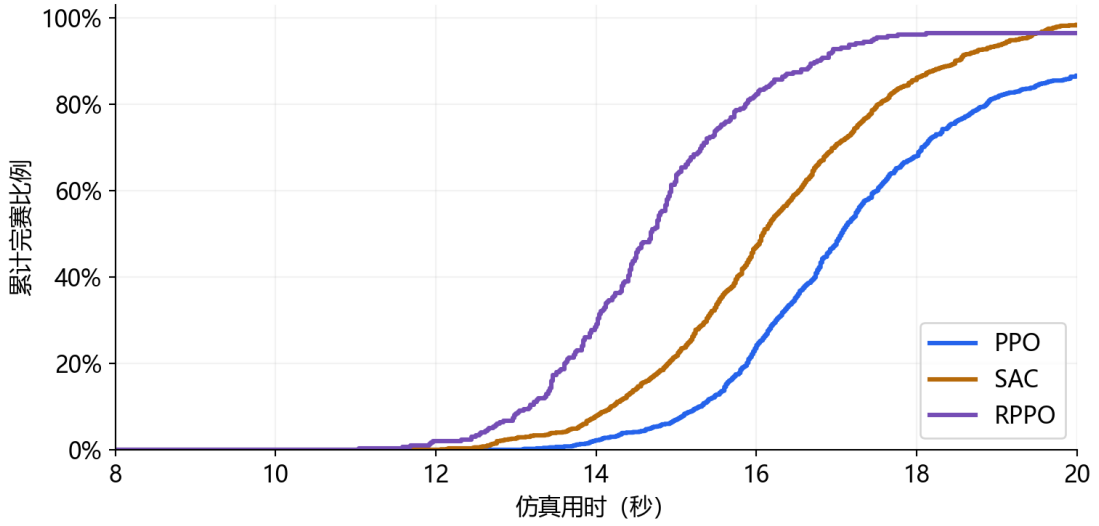


图 3-5　不同时间内完成赛道的回合比例

限时完赛曲线以全部评估回合为分母。曲线靠左的部分代表较早完成的回合，20 秒处的高度对应最终完赛率。RPPO 在较短时间内累计的完赛回合较多，SAC 在接近时间上限时达到最高的累计比例。三个方案的测试赛道相同，训练预算、控制映射和种子数量仍有差异，表中差值反映完整驾驶方案的表现。

4 个人感想与思考

4.1 主要收获

这次课程设计让我体会到，强化学习项目中环境定义与结果统计直接影响最后的判断。我在整理回合记录时发现，即使车辆已经访问绝大多数路块，仍可能因为超时而未完赛。明确记录终止状态、回合用时与覆盖率之后，才有办法把仿真中的行为与统计结果对应起来。

我也学会了同时从整体指标和具体案例观察模型。完赛率反映模型能够完成多少条赛道，完赛平均用时反映已完成回合的速度，录像则帮助定位失败的阶段。例如，PPO 草地旋转和 RPPO 路缘停滞都可能得到相同的“超时”标签，但车轮接触、车速与覆盖率记录呈现了不同的行为。逐回合数据在这里直接影响对失败的解释。

在协作方面，我认识到共享接口和记录格式是算法比较的基础。只知道某模型有两个输出还不足以理解它的控制方式，需要进一步核对两个量的具体含义、车辆如何执行动作，以及每个回合怎样结束。把这些约定提前写清楚，可以减少联调、汇总和汇报时的反复核对。

4.2 不足与改进思路

第一，三套方案的控制映射、训练预算和训练种子数存在差异，当前结果主要评价完整方案。后续可以安排同状态、同动作映射、同预算的对照，并为 RPPO 补充训练种子，进一步观察算法结构及训练随机性对结果的影响。

第二，代表性视频覆盖的失败类型有限。可以在逐赛道记录中增加首次明显离路时刻、低速持续时间、起点重入、覆盖率停滞时长和终点控制触发时刻。借助这些字段，可以在较大样本上统计各类失败的比例，并定位终点控制最常介入的场景。

第三，效果展示还可以增加同赛道的时间对齐视图。让三种方案在弯道入口、弯心和出口对齐，配合速度、转向、制动和车轮接触曲线，可更具体地比较它们何时减速、如何转向，以及为什么会在同一位置出现不同结果。

5 其他小组展示的启示

5.1 印象较深的工作

我印象较深的是一个横版飞行跑酷游戏的小组。他们先对游戏画面进行像素分块，再标记其中的危险块，把原来需要逐像素处理的画面转换成较紧凑的空间表示。模型输入保留了危险区域的分布，输入维度随之下降。

这个做法将状态设计和任务目标直接联系起来。在飞行跑酷中，危险区域相对角色的位置会影响下一步动作。通过分块保留这类空间关系，可以减少画面细节占用的输入空间，并让人更容易检查模型接收了哪些与避险有关的信息。

5.2 对本组工作的启发

这个案例让我重新审视赛车任务中的道路状态。赛车需要根据前方道路曲率、车辆偏移和当前速度作出决策。按车辆坐标提取前方道路预瞄点，与飞行跑酷中的危险块标记有相似之处，都在尝试保留对下一步动作有影响的空间关系。

后续可以在现有状态上开展逐项消融，例如改变预瞄点的数量和间距，观察急弯、连续弯道及终点附近的表现。若引入分块式道路表示，可以按车身前方和两侧的位置描述道路边缘与可行驶区域，并在相同赛道和预算下检验效果。比较时可同时记录输入维度、完赛率、用时与典型失败，判断状态压缩后是否仍保留了控制所需的信息。

参考文献

[1] Farama Foundation. Car Racing. Gymnasium Documentation.

[2] Schulman J, Moritz P, Levine S, et al. High-Dimensional Continuous Control Using Generalized Advantage Estimation. ICLR, 2016.

[3] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms. 2017.

[4] Haarnoja T, Zhou A, Abbeel P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor. ICML, 2018.

[5] Haarnoja T, Zhou A, Hartikainen K, et al. Soft Actor-Critic Algorithms and Applications. 2018.